

체압 분포 영상의 초고해상도 보정을 이용하는 욕창 예방을 위한 자세 예측 알고리즘

Posture Prediction Algorithm for Pressure Ulcer Prevention using Super Resolution Reconstruction of Pressure Distribution Image

김진규¹, 심명훈¹, 배은경¹, 문영진^{1,2}, 최재순^{1,2*}
 (Jin-Gyu Kim¹, Myoung-hoon Shim¹, EunKyung Bae¹, YoungJin Moon^{1,2}, JaeSoon Choi^{1,2*})

¹Department of Convergence Medicine, University of Ulsan College of Medicine, Asan Medical Center, Seoul

²Department of Biomedical Engineering, University of Ulsan College of Medicine, Asan Medical Center, Seoul

Abstract: In this study, we proposed Super-Resolution (SR) techniques to reconstruct a High-Resolution (HR) pressure image from a Low-resolution (LR) body pressure image in order to solve the limitations of sensor resolution when to predict pressure ulcer spots. We implemented Super-Resolution Generative Adversarial Network (SRGAN) for pressure image reconstruction and Convolution Neural Network(CNN) for posture prediction. To evaluate the similarity between the original pressure image and the 4× rescaled LR body pressure image which was restored by SR technology, Image Quality Assessment (IQA) technology and peak signal-to-noise (PSNR) and structural similarity (SSIM) were used. The reconstruction pressure images are classified into for postures (Supine, Right Side, Left Side, Others) to predict the patient's posture with 98.37% accuracy.

Keywords: Pressure Ulcer, Super Resolution, Generative Adversarial network, Posture detection

1. 서론

EPUAP(European Pressure Ulcer Advisory Panel)에 따르면 욕창은 압력, 전단, 마찰, 그리고 온도, 습도와 같은 복합적 요인들의 조합으로 인해 신체 돌출부에 주로 나타나는 피부 및 지지 조직의 국부적인 손상을 의미한다. [1]. 그 중 압력은 욕창 발생의 주 원인이 되는 요인으로 대개 오래 병상에 누워 있는 중증 환자, 고령자, 입원환자 등 사이에서 자주 발생하며, 장시간 동안 높은 압력에 노출되기 쉬운 등, 천골, 머리, 엉덩이, 팔꿈치, 발 뒤꿈치 등과 같은 돌출된 신체 부위에 발생할 위험도가 높다[2]. 욕창 발생 이후 오랜 시간이 지날 경우 손상된 신체 일부를 수술을 통해 절단해야 하거나, 심각한 경우 추가적인 질환의 원인이 되어 사망 위험도를 높이기 때문에 욕창이 생기지 않도록 사전에 예방하는 것이 매우 중요하다. EPUAP에서는 욕창을 증상에 따라 4단계로 분류하고 정기적으로 검사, 예방, 치료하는 방법을 제시한다[3].

욕창 발생의 원인이 되는 여러가지 요인들 중 전단력은, 가장 직접적으로 욕창을 발생시키는 요인으로 알려져 있으며, 이는 신체부위에 가해지는 압력에 비례한다. 때문에, 욕창 발생 정도를 낮추기 위해 실제 병실 현장에서는 간호사 혹은 간병인들이 욕창 발생 위험도가 높은 환자의 자세를 수작업으로 매 1~2 시간 간격으로 바꾸어 줌으로써 집중된 압력을 주기적으로 해소해주고 있다. 그러나, 이러한 조치를 24 시간 내내 유지하는 것은 현실적으로 시간-비용 면에서 쉽지 않은 작업이기에, 지속적이고 자동적으로 체압을 관리해 주

는 시스템의 필요성이 대두되고 있다. 이를 위해서, 대다수의 연구자들은 대상의 신체에 가해지는 전단력의 정도를 실시간으로 추정 혹은 분석하고 욕창 발생 가능성이 높은 부위를 분류할 수 있는 모니터링 기능 구현을 위해, 압력 측정 매트리스와 같은 체압 분포 측정 장비를 주로 활용하고 있다.

체압 분포 데이터에 기반한 욕창 위험도 모니터링에 이어서, 욕창 위험도에 따라 압력해소를 위한 최적의 자세로 환자의 자세를 변경해 주는 것은 욕창 예방 과정에 있어서 반드시 수반되어야 한다. 이 과정에서는 환자의 현재 자세와 체압 분포 데이터, 그리고 과거 자세와 체압 분포 데이터를 임의의 피부 강도 모델에 적용시킴으로써, 이후 가장 효과적으로 신체 전반의 욕창 위험도를 완화시킬 수 있는 최적의 자세를 예측 가능하게 해줄 수 있다. 따라서, 환자의 현재 자세를 파악하는 것은 욕창 예방이라는 목적 달성을 위해서 필수적이다.

일반적으로, 대상의 자세 파악은 카메라 등을 통해 수집된 영상 정보에서 대상 관절의 공간상 위치 정보를 추출하는 방식이 활용되지만, 병원과 같이 개인정보 취급에 민감한 기관에서는 권장되지 않는다. 때문에 일부 연구에서는, 영상 정보 대신 체압 분포 정보를 활용하여 대상의 자세 정보를 추출해 내는 방식을 제안하고 있다[4]. 하지만 보편적인 체압 분포 정보는 영상 정보에 비해 그 해상도가 극히 낮은 편이기 때문에, 정확한 판단을 위해서는 낮은 해상도의 체압 데이터의 해상도를 향상시키기 위한 알고리즘의 필요성이 요구된다

* Corresponding Author
 Manuscript received February 10, 2021;

※ 본 연구는 산업부 인공지능 기반 욕창예방을 위한 자율형 침대로봇 개발 사업(20005004)에 의하여 연구되었음.

따라서, 본 연구에서는 단순 모니터링에 그치지 않고 효과적이고 실질적으로 욕창 예방을 위해서, 대상의 정확한 자세를 체압 분포로부터 추정해내는 알고리즘을 개발하고자 한다. 그러나 앞서 기술한 바와 같이, 체압 분포 데이터는 사용되는 센서의 단면적으로 인해 달성 가능한 해상도의 한계가 존재하며, 높은 측정 해상도를 위해서 필요한 센서 수가 늘어나게 되면 측정 장비의 가격 역시 기하급수적으로 증가하게 된다. 때문에, 이러한 고질적인 비용 문제의 해결을 위해서, 본 연구에서는 컴퓨터 비전 분야에서 이미지와 비디오의 해상도를 향상시키는 SR 기법과, 딥러닝 알고리즘에 기반한 SRGAN 기술을 활용하여, 저 해상도의 체압 분포 데이터(혹은 이미지)를 고해상도 이미지로 복원시킴으로써 더욱 정밀한 자세 추정 결과를 기대할 수 있는 알고리즘을 제시한다.

이후 각 논문은 다음과 같이 구성된다. 2장에서는 저해상도의 이미지를 고해상도로 보정하는 알고리즘과 체압 분포 이미지에서 자세 정보를 추정하는 알고리즘에 대해 기술한다. 또한, 알고리즘의 성능 검증을 위해서, 실제 측정된 체압 분포 이미지의 라벨링 과정과, 사용된 정량적 평가방법에 대해서 기술한다. 최종적으로 계산된 수치들을 바탕으로, 제시한 알고리즘의 성능에 대한 결과를 보여준다.

II 본론

본 연구에서 제안하는 **환자의 자세 예측을 위한** 알고리즘은 **두 가지의 인공지능망 알고리즘을 각 단계에 활용하여** 구성되었으며, **저해상도 체압 이미지의 고해상도 보정과 보정된 이미지를 통한 자세 검출의 과정을 각각 수행한다.** 첫 단계에서는, 고해상도 보정을 위한 SR기법인 SRCNN와 SRCNN에서 고주파세부사항(High frequency detail)과 지각적인 부분이 보완된 SRGAN 기술을 이용하여 저해상도 전신 체압 분포 이미지를 고해상도 체압 분포 이미지로 보정하였다. 다음 단계에서는, 보정된 이미지를 기반으로 One-Hot Encoding을 이용한 자세 라벨링을 진행하여 CNN 기술을 이용한 자세 검출 네트워크를 학습하였다.

2.1 저해상도이미지 고해상도 보정 알고리즘

자세 예측을 위한 최적 결과를 검토하기 위해서, 앞서 기술한 저해상도 이미지의 고해상도 보정 알고리즘인 SRCNN과 SRGAN의 두 가지 방식을 활용하여 학습을 진행하였다. SRCNN은 단일 이미지 초해상도(Single Image Super-resolution)에 최초로 딥 러닝을 적용한 기술로써, 간단한 구조로 기존의 SR방법보다 좋은 성능을 보여 많은 연구자들이 SR 문제에 딥 러닝을 적용하는 계기를 제공하였다. SRCNN은 저해상도 이미지를 입력받아, Patch extraction & representation - Non-linear mapping - Reconstruction의 과정을 거쳐 고해상도 이미지로 출력한다 (그림 1 참고)..




그림 1 SRCNN을 이용한 저해상도 이미지 복원 모델

Figure 1 Low-resolution image restoration model using SRCNN

먼저 패치 추출 및 표현 모듈은 저해상도 이미지들에서 패치들을 추출하는 과정, 비선형 매핑은 다차원 패치 벡터를 다른 차원 패치 벡터로 매핑하는 과정, 재구성 모듈은 다차원 패치 벡터에서 고해상도 이미지를 생성하는 과정으로 3개의 과정이 컨볼루션 레이어 (Convolutional Layer)로 이루어져 진행된다[5].

SRCNN은 인공지능 학습을 시킬 때의 loss function, $L(\theta)$, 는 MSE(Mean Square Error)를 사용하여 진행되었다. MSE loss function은 일반적인 딥 러닝 모델들에 많이 쓰이는 기술로 MSE를 나타내는 수식(1)은 다음과 같다.

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n \|F(Y_i; \theta) - X_i\|^2 \quad (1)$$

θ 는 CNN의 Layers의 feature maps의 크기와 패치의 차원을 나타내며 F 는 각 layers의 매핑함수이며, Y_i 는 저해상도 이미지의 집합, X_i 는 고해상도의 이미지 집합이다.

MSE는 전체적인 학습에는 좋은 결과는 보이지만 high frequency의 특징을 나타내는 지표로는 좋은 성능을 보이지 못하여 해당 부분을 보완하기 위한 다양한 SR 딥 러닝 모델들이 활용되고 있다.

SRGAN은 이전에 SRCNN과 같은 SR기술들은 MSE의 차이를 최소화 함으로써 PSNR을 높게 만들어 해상도 보정방법으로, 제안된 기술들의 고주파세부사항의 한계를 개선하기 위하여 개발된 네트워크이다. [그림2]와 같이 생성 (Generative) 네트워크와 판별(Discriminative) 네트워크로 2가지의 큰 네트워크로 구성되어있다. 판별 네트워크는 검토한 각각의 데이터 인스턴스가 실제 트레이닝 데이터 세트인지 아닌지를 저해상도 이미지에서 고해상도 이미지를 추정한다. 주어진 저해상도 이미지를 그에 상응하는 고해상도 이미지 짝을 생성하는 Generating function G를 훈련한다. 학습 진행방식은 Real part에서는 고해상도 이미지를 넣음으로 판별네트워크가 고해상도 이미지를 구분하게 만들고, Fake part에서는 저해상도 이미지로 생성네트워크가 생성한 이미지를 넣음으로써 보정된 이미지를 고해상도 이미지로 속이는 적대적 학습을 하는 것이 핵심이다. 이러한 학습 과정을 통해서 최종적으로 생성네트워크는 판별네트워크를 속이기 위해 원본과 유사한 고해상도이미지를 만들어 내는 결과를 보여준다.




그림 2 원본 SRGAN 모델
Figure 2 Original SRGAN model architecture

SRGAN에서는 픽셀공간에서의 유사성이 아닌 시각적 유사도(perceptual similarity)에 기반하여 content loss와 adversarial loss로 구성된 perceptual loss function을 이용하여 이미지를 보정하는 기술이 제안되었다[6]. 앞서 SRCNN의 이미지 보정 방식의 문제점을 보완하고자 SRGAN에서는 손실 함수(loss function)을 content loss와 adversarial loss의 두 가지 방법으로 설명한다.

2.1.1. Content loss(콘텐츠 손실)

보통 MSE를 기반으로 사용할 때 pixel-wise MSE loss를 사용하지만 이러한 방식은 텍스처를 부드럽게 하기 때문에 high frequency content details을 흐리게 보이게 한다. 따라서 SRGAN에서는 해당 문제를 해결하기 위하여 pre-train model인 VGG19의 activation function ReLU를 기반으로 content loss를 아래 수식(2)과 같이 구성하였다.

$$l_{VGG/i,j}^{SR} = \frac{1}{W_{i,j}H_{i,j}} \sum_{x=1}^{W_{i,j}} \sum_{y=1}^{H_{i,j}} (\phi_{i,j}(I^{HR})_{x,y} - \phi_{i,j}(G_{\theta_G}(I^{LR}))_{x,y})^2 \quad (2)$$

I^{LR} 은 low-resolution image, I^{HR} 은 high-resolution image을 나타내는 말이며, $W_{i,j}$ 와 $H_{i,j}$ 은 VGG 네트워크 내의 각 feature maps을 차원을 설명하며 $\phi_{i,j}$ 은 VGG19 네트워크 내에서 i번째 매핑 계층과 j번째 컨볼루션에 의해 얻는 특성을 나타내며 $G_{\theta_G}(I^{LR})$ 은 저해상도 이미지가 고해상도로 재구성된 이미지이다.

2.1.2. Adversarial loss(적대적 손실)

이 부분은 이미지 손실을 최소화하기 위한 일종의 방식으로 GAN에서 주로 사용하는 방식이다. 기본적으로 $\log(1-x)$ 는 훈련 초기 gradient가 flat한 경향이 있어 이것을 역으로 바꾼 $-\log(x)$ 방식을 사용한다. 아래 수식(3)과 같이 변경된 방식은 gradient초기값은 매우 크게 나타나지만 Generator가 고해상도인 상태로 훈련되기 위한 학습으로 좋은 효과를 보여준다[6].

$$l_{Gen}^{SR} = \sum_{n=1}^N -\log D_{\theta_D}(G_{\theta_G}(I^{LR})) \quad (3)$$

D_{θ_D} 은 재구성된 이미지 $G_{\theta_G}(I^{LR})$ 가 원본 고해상도이미지일

확률이다.

따라서 위에 설명한 2가지의 손실 함수를 더하여 최종적으로 아래 수식(4)와 같은 Perceptual loss function이 완성된다 [10].

$$l^{SR} = l_{VGG/i,j}^{SR} + 10^{-3}l_{Gen}^{SR} \quad (4)$$

본 연구에서는 기존의 판별 네트워크에서 체압 분포 이미지의 크기에 적합한 학습을 진행하기 위하여 판별네트워크 Layer의 Kernel Size를 3x3로 수정하였고 Moment는 0.9으로 수정, Leaky ReLU는 0.2, Dropout은 0.2와 같이 기존의 SRGAN에서 매개변수값을 변경하여 구성하였다[그림 3].




그림 3 체압분포데이터에 맞추어 변경한 SRGAN 모델
Figure 3 Fine-tuning SRGAN model architecture for body pressure data

2.2. 체압분포이미지 자세 검출 알고리즘

CNN은 합성곱 신경망 모델로서 컨볼루션 레이어와 풀링 레이어(pooling Layer)라는 고유의 구조를 더한 신경망 네트워크다. 자세 검출을 위해 CNN의 손실 함수를 이용하여 실제 값과 예측 값의 차이를 최소화하여 두개의 매개변수인 가중치 W와 편향 b를 찾아가는 딥 러닝의 학습 과정으로 Cross Entropy를 이용하여 다중 클래스 분류 학습을 진행하였다[그림 4]. 인공지능 알고리즘 정확도 결과값은 다중 분류 손실 함수 (Categorical Cross Entropy)값을 이용하여 자세 검출 정확도를 측정하였다.




그림 4 환자의 자세 검출 알고리즘 모델
Figure 4 Patient's posture detection model

2.3 체압분포이미지의 획득 및 라벨링

압력 데이터셋은 계명대학교 사용성 평가 센터의 전신체 압측정기 (Pliance, Novel Inc)을 이용하여 획득하였다. 전신압력측정기를 통해 64×32 (2048 센서) 해상도의 이미지를 총 3가지 자세(Supine, Right Log, Left Log), **각각 600장씩 총 1800장**의 이미지를 획득, Open Dataset[7]은 Vista medical FSA SoftFlex을 통해 64×32 (2048 센서) 해상도의 이미지를 총 중 3가지 자세(Supine, Right Log, Left Log), **각각 1000장씩 총 3000장**의 이미지를 획득, 자체 평가용 전신체압측정기(BPMS, 테크스톰 Inc)을 이용하여 입력 데이터는 48×16 (768 센서) 해상도의 이미지를 총 3가지 자세(Supine, Right Log, Left Log), **각각 400장씩 총 1200장**의 이미지를 획득하였다 $\times 4$ Downscale을 진행하여 Supervised Learning 에 사용되었다.

각 획득한 이미지는 One-hot Encoding을 통해 4가지의 자세(Supine, Right log, Left Log, Others)로 각각 이미지의 자세에 대한 분류를 진행하였으며, 체압측정기로 획득한 이미지를 3가지의 자세를 각도 변환(-15° , -10° , -5° , 0° , 5° , 10° , 15°)을 진행한 이미지 중 $\pm 10^\circ$, $\pm 15^\circ$ 를 Others로 분류하여 학습을 진행하였다.




그림 5 전신압력측정기를 이용한 전신압력측정결과
Figure 5 body pressure measurement result using pressure mat

2.4 정확도 평가방법

앞서 제안한 SRGAN 기술은 이미지 품질 평가 기술(IQA)을 사용하였다[8]. 최대 신호 대 잡음 비(PSNR)은 영상 정보, 화질을 평가할 때 사용하는 기술로서 아래 식 (5) 과 같다. 품질이 좋은 이미지는 큰 PSNR값을 가지며, 품질이 좋지 않은 이미지는 작은 PSNR값을 가지게 된다.

$$PSNR = 20 \cdot \log_{10}(MAX_I) - 10 \cdot \log_{10}(MSE) \quad (5)$$

MAX_I 은 해당 이미지의 최댓값으로서 해당 채널의 최댓값에서 최솟값을 빼서 구할 수 있다.

구조적 유사도(structural similarity)는 PSNR의 한계를 극복하기 위해 개발된 기술로서 수식(6)은 아래와 같다. 사람의 시각 능력과 일치시키는 목적으로 개발되었다. 사람은 영상에서 구조 정보를 반영하여 영상을 바라보게 되는데, 영상이 얼마나 구조 정보를 변화 시키는 가를 측정하는 기술이다.

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (6)$$

$\mu_x, \mu_y, \sigma_x, \sigma_y, \sigma_{xy}$ 는 이미지 x, y의 국소 평균, 표준 편차, 교차 공분산입니다.

최종적으로 고해상도 보정에 대한 정확도는, 상기 두 가지의 이미지 평가 기술을 사용하여 평가되었으며, 자세 검출에 대한 CNN 알고리즘은 아래의 다중 분류 손실 함수 (식 7)을 이용하여, 실측 값과 예측 값의 차이에 기반하여 정확도가 평가되었다. 자세 검출에 대한 CNN 알고리즘은 아래의 다중 분류 손실 함수를 이용하여 실측 값과 예측 값의 차이를 수식(7)과 같이 이용하여 정확도를 평가하였다.

$$CE = - \sum_i^C t_i \log\left(\frac{e^{s_i}}{\sum_j^C e^{s_j}}\right) \quad (7)$$

t_i 은 ground truth(정답), s_i 는 각 클래스 i 에 대한 CNN의 마지막 층의 output인 Score 벡터의 i 번째 요소이다. C 는 분류할 카테고리의 수를 나타낸다.

III. 결과

앞서 정의한 이미지 평가 방식에 따른 계산 결과를 보여준다. 결과를 통해 원본이미지를 CV2.resize 확대 기술, SRCNN, SRGAN와 원본이미지를 이용하여 고해상도 이미지로 복원한 결과를 보여준다[그림 6-8].




그림 6 Supine 자세의 고해상도 전신체압이미지와 저해상도이미지를 왼쪽부터 cv2.resize, SRCNN, SRGAN 를 이용하여 보정 결과 및 원본과의 유사도 평가 값

Figure 6 SR restoring result of LR pressure Supine image, from left to right cv2.resize(bicubic interpolation), SRCNN, SRGAN, Original image. Corresponding PSNR, SSIM and MSE are shown in the legend




그림 7 Left Log 자세의 고해상도 전신체압이미지와 저해상도이미지를 왼쪽부터 cv2.resize, SRCNN, SRGAN 를 이용하여 보정 결과 및 원본과의 유사도 평가 값

Figure 7 SR restoring result of LR pressure Left log image, from left to right cv2.resize(bicubic interpolation), SRCNN, SRGAN, Original image. Corresponding PSNR,SSIM and MSE are shown in the legend




그림 8 Right Log 자세의 고해상도 전신체압이미지와 저해상도이미지를 왼쪽부터 cv2.resize, SRCNN, SRGAN 를 이용하여 보정 결과 및 원본과의 유사도 평가 값

Figure 8 SR restoring result of LR pressure Right log image, from left to right cv2.resize(bicubic interpolation), SRCNN, SRGAN, Original image. Corresponding PSNR,SSIM and MSE are shown in the legend

[표 1]을 보면 SRGAN의 결과는 원본이미지와 유사성을 나타내며 결과이미지의 PSNR과 SSIM을 bicubic 과 SRCNN의 비교 결과를 보여준다. SRGAN을 이용한 고해상도 복원 결과는 Supine자세에서는 PSNR 37.17dB, SSIM 0.9622, Right Log 자세에서는 27.02dB, SSIM 0.9224, Left Log자세에서

는 31.44dB, SSIM 0.9470으로 적용된 다른 기술들에 비해 높은 결과를 보여주었다. 이를 통해서 SRGAN 알고리즘이 저해상도 이미지의 고해상도 이미지로의 복원에서 더 뛰어난 성능을 나타냄을 확인하였다

보정 이미지의 자세 검출 알고리즘은 손실 함수를 이용하여 결과 도출하였고 반복학습을 통하여 일정한 정확도에서 수렴함을 확인하였고 98.37%의 정확도 결과를 나타내었다[그림 9].

표 1 압력이미지 데이터에서 SRCNN, SRGAN 에 대한 이미지평가기술 결과

Table 1 IQA on pressure image data

이미지 평가 기술	Bicubic(cv2.resize)			SRCNN			SRGAN		
	Supine	Right Log	Left Log	Supine	Right Log	Left Log	Supine	Right Log	Left Log
PSNR(dB)	23.32	22.99	26.16	24.29	24.25	27.90	37.17	27.02	31.44
SSIM	0.7955	0.8477	0.8348	0.8049	0.7389	0.7573	0.9622	0.9224	0.9470




그림 9 보정된 체압분포 이미지의 학습셋과 검증셋에 의한 자세 검출 알고리즘 손실계산 결과

Figure 9 Loss function result of posture detection algorithm based on body pressure distribution image

IV. 결론

본 연구에서는 우리는 인공지능을 이용하여 저해상도 체압 데이터 이미지를 고해상도 체압 데이터 이미지로 변환하는 기술과 자세를 검출하는 알고리즘을 이용하여 저해상도의 체압 센서를 이용한 환자의 욕창을 검출 및 예방하는 기술을 제안한다. 제안된 접근 방식인 SRGAN 을 통하여 저해상도 체압분포이미지가 고해상도 체압분포이미지로 보정함에 Supine 자세에서 PSNR값 37.1792와 SSIM값 0.9622, Right Log자세에서 PSNR값 27.02와 SSIM값 0.9224, Left Log자세에서 PSNR값 31.44와 SSIM값 0.9470으로 Bicubic(cv2.resize)와 SRCNN과 비교하여 PSNR에서는 비슷하거나 높은 값을 보여지며 SSIM에서 다른 SR기법보다 원본이미지와 높은 유사함을 나타냄으로써 우수한 성능을 달성하였다. 또한 저해상도의 전신체압측정기의 압력 분포를 측정하여 98.37%의 정

확도로 환자의 자세를 예측하고 현재 환자의 어떠한 부위가 지속적으로 높은 압력이 측정이 되며 해당 부위의 체위를 변경할 수 있는 부위 및 시간 등을 사용자에게 제공하는 인공지능 네트워크를 통하여 자동적으로 욕창을 예측 및 예방하는 기술[9,11]을 추후 동아대병원과 협력하여 임상시험을 진행하여 정밀한 네트워크로 최적화 학습을 진행할 예정이다.

REFERENCES

- [1] European Pressure Ulcer Advisory Panel (EPUAP), Guidelines on treatment of pressure ulcers, EPUAP Rev. 1 (1999) 31–33.
- [2] S. Tsuji, S. Ichioka, N. Sekiya, T. Nakatsuka, Analysis of ischemia-reperfusion injury in a microcirculatory model of pressure ulcers, *Wound Repair Regen.* 13 (2) (2005) 209–215.
- [3] D. Gawlitta, W. Li, C.W.J. Oomens, F.P.T. Baaijens, D.L. Bader, C.V.C. Bouten, The relative contributions of compression and hypoxia to development of muscle tissue damage: an in vitro study, *Ann. Biomed. Eng.* 35 (2) (2007) 273–284.
- [4] M. Baran Pouyan, J. Birjandtalab, M. Nourani, and M. D. Matthew Pompeo, “Automatic limb identification and sleeping parameters assessment for pressure ulcer prevention,” *Comput. Biol. Med.*, vol. 75, pp. 98–108, 2016.
- [5] C. Dong, C. C. Loy, and K. He, “Image Super-Resolution Using Deep Convolutional Networks,” pp. 1–14.
- [6] C. Ledig et al., “Photo-realistic single image super-resolution using a generative adversarial network,” *Proc. - 30th IEEE Conf. Comput. Vis. Pattern Recognition, CVPR 2017*, vol. 2017-Janua, pp. 105–114, 2017, doi: 10.1109/CVPR.2017.19.
- [7] H. Ahn, L. Cowan, C. Garvan, D. Lyon, and J. Stechmiller, “Risk Factors for Pressure Ulcers Including Suspected Deep Tissue Injury in Nursing Home Facility Residents: Analysis of National Minimum Data Set 3.0,” *Adv. Ski. Wound Care*, vol. 29, no. 4, pp. 178–190, 2016.
- [8] C.-Y. Yang, C. Ma, and M.-H. Yang, Single-image super-resolution: A benchmark. In *European Conference on Computer Vision (ECCV)*, pages
- [9] M. Baran Pouyan, J. Birjandtalab, M. Nourani, and M. D. Matthew Pompeo, “Automatic limb identification and sleeping parameters assessment for pressure ulcer prevention,” *Comput. Biol. Med.*, vol. 75, pp. 98–108, 2016.
- [10] D. P. Kingma and J. L. Ba, “Adam: A method for stochastic optimization,” *3rd Int. Conf. Learn. Represent. ICLR 2015 - Conf. Track Proc.*, pp. 1–15, 2015.
- [11] J. Seon, S. Jin, and J. Hyun, “중환자실 환자의 욕창 관련 경계압력 예측요인,” 2017.