

체압 분포 영상 초고해상도 보정을 이용한 욕창 예방을 위한 환자 자세 추정

Patient Posture Estimation Using Super-Resolution Reconstruction of Pressure Distribution Image for Pressure Ulcer Prevention

김진규¹, 심명훈¹, 배은경¹, 문영진², 최재순^{3,*}
(Jin-Gyu Kim¹, Myoung-hoon Shim¹, Eunkyung Bae¹, Youngjin Moon², and Jaesoon Choi^{3,*})

¹Asan Institute for Life Sciences, Asan Medical Center, Seoul

²Department of Convergence Medicine, University of Ulsan College of Medicine, Asan Medical Center, Seoul

³Department of Biomedical Engineering, University of Ulsan College of Medicine, Asan Medical Center, Seoul

Abstract : In this study, to improve the prediction of pressure ulcer spots, we have developed super-resolution (SR) techniques to reconstruct a high-resolution (HR) pressure image from a low-resolution (LR) body pressure image to overcome the limitations of sensor resolution. We implemented a super-resolution generative adversarial network (SRGAN) to reconstruct pressure images and a convolution neural network (CNN) to predict posture. To evaluate the similarity between the original pressure image and the 4× rescaled LR body pressure image restored using SR technology, we used image quality assessment (IQA) technology, peak signal-to-noise ratio (PSNR), and structural similarity (SSIM). The reconstructed pressure images were classified into four patient postures (supine, right side, left side, and others) with 98.37% accuracy showing the feasibility of practical implementation.

Keywords: Pressure ulcer, super-resolution, generative adversarial network, posture detection

I. 서론

European Pressure Ulcer Advisory Panel (EPUAP) 에 따르면 욕창은 압력, 전단, 마찰, 그리고 온도, 습도와 같은 복합적 요인들의 조합으로 인해 신체 돌출부에 주로 나타나는 피부 및 지지 조직의 국부적인 손상을 의미한다[1]. 그 중 압력은 욕창 발생의 주 원인이 되는 요인으로 대개 오래 병상에 누워있는 중증 환자, 고령자, 입원환자 등에서 자주 발생하며, 장시간 동안 높은 압력에 노출되기 쉬운 등, 천골, 머리, 엉덩이, 팔꿈치, 발 뒤꿈치 등과 같은 돌출된 신체 부위에 발생할 위험도가 높다[2]. 욕창 발생 이후 오랜 시간이 지날 경우 손상된 신체 일부를 수술을 통해 절단해야 하거나, 심각한 경우 추가적인 질환의 원인이 되어 사망 위험도를 높이기 때문에 욕창이 생기지 않도록 사전에 예방하는 것이 매우 중요하다. EPUAP에서는 욕창을 증상에 따라 4단계로 분류하고 정기적으로 검사, 예방, 치료하는 방법을 제시한다[3].

욕창 발생의 원인이 되는 여러가지 요인들 중 전단력은 가장 직접적으로 욕창을 발생시키는 요인으로 알려져 있

며, 이는 신체부위에 가해지는 압력에 비례한다. 때문에, 욕창 발생 정도를 낮추기 위해 실제 병실 현장에서는 간호사 혹은 간병인들이 욕창 발생 위험도가 높은 환자의 자세를 수작업으로 매 1~2 시간 간격으로 바꾸어 줌으로써 집중된 압력을 주기적으로 해소해 주고 있다. 그러나 이러한 조치를 24시간 내내 유지하는 것은 현실적으로 시간-비용 면에서 쉽지 않은 작업이기에, 지속적이고 자동적으로 체압을 관리해 주는 시스템의 필요성이 대두되고 있다. 이를 위해서, 대다수의 연구자들은 대상의 신체에 가해지는 전단력의 정도를 실시간으로 추정 혹은 분석하고 욕창 발생 가능성이 높은 부위를 분류할 수 있는 모니터링 기능 구현을 위해, 압력 측정 매트리스와 같은 체압 분포 측정 장비를 주로 활용하고 있다.

체압 분포 데이터에 기반한 욕창 예방 기법은 체압 모니터링과 이를 바탕으로 한 환자 자세 인식과 욕창 위험도 추정, 예상 위험 부위 압력 누적 해소를 위한 환자 자세 변경 계획과 실제 자세 변경 실행의 과정으로 나누어 볼 수 있다. 환자의 현재 자세와 체압 분포 데이터, 그리고 과거 자세와 체압 분포 데이터를 피부 강도 모델에 적용시킴

*Corresponding Author

Manuscript received February 19, 2021; revised April 4, 2021; accepted April 22, 2021

김진규: 서울아산병원 아산생명과학연구원, 울산대학교 대학원 (kingk3793@naver.com, ORCID[®] 0000-0001-8828-8333)

심명훈: 아산생명과학연구원, 서울아산병원 (bluecanvas2119@gmail.com, ORCID[®] 0000-0003-1383-6029)

배은경: 아산생명과학연구원, 서울아산병원 (ekbea8765@gmail.com, ORCID[®] 0000-0001-6618-7371)

문영진: 울산대학교 의과대학, 서울아산병원 아산생명과학연구원 (jacobian@amc.seoul.kr, ORCID[®] 0000-0002-8573-1149)

최재순: 울산대학교 의과대학, 서울아산병원 아산생명과학연구원 (fides@amc.seoul.kr, ORCID[®] 0000-0002-6817-618X)

※ 본 연구는 산업부 인공지능 기반 욕창예방을 위한 자율형 침대로봇 개발 사업(20005004)에 의하여 연구되었음.

로써 욕창 위험부위와 효과적으로 욕창 위험을 완화시킬 수 있는 자세의 도출이 가능할 수 있다. 따라서, 체압 분포 데이터로부터 환자의 현재 자세를 파악하는 것이 가장 핵심적인 과정이라 할 수 있다.

대상의 자세 파악은 광학 카메라 등을 통해 수집된 영상 정보로부터 대상 관절의 공간상 위치 정보를 추출하는 방식으로 용이하게 구현이 가능하나, 개인정보보호가 중요한 병원 환경에서 적합한 도구로 권장되지 않는다. 때문에 일부 연구에서는 영상 정보 대신 체압 분포 정보를 활용하여 대상의 자세 정보를 추출해 내는 방식을 제안하고 있다[4]. 하지만, 체압 분포 측정은 이미징 센서와는 달리 압력 센서를 조밀하게 구성하면 비용 면에서 실용성이 크게 떨어지게 되고, 조밀한 구성의 센서를 사용하여도 영상 정보에 비해 형상 정보의 양이 낮아, 실용적인 센싱 방식 구현을 위해서 적은 수의 압력 센서를 이용하는 낮은 해상도의 체압 데이터를 바탕으로 높은 해상도의 정보를 추정해 내는 알고리즘이 유용하게 이용될 수 있다.

본 연구에서는 임상 현장에서 실용성이 높은 시스템을 구현할 수 있도록, 적은 수의 센서로 구성된 저해상도 체압 분포 데이터를 사용하되, 욕창 위험도 예측을 위한 환자의 자세 정보를 적절한 수준으로 추정해 내는 알고리즘을 개발하고자 하였다. 컴퓨터 비전 분야에서 이미지와 비디오의 해상도를 향상시키는 super-resolution (SR) 기법의 하나인 딥러닝 알고리즘에 기반한 super-resolution generative networks (SRGAN) 기법을 활용하여 저해상도의 체압 분포 데이터를 고해상도 데이터로 향상 시키는 방법을 시도하였다.

본 논문은 다음과 같이 구성된다. 저해상도의 이미지를 고해상도로 보정하는 알고리즘과 체압 분포 이미지에서 자세 정보를 추정하는 알고리즘에 대해 기술하고, 알고리즘의 성능 검증을 위한 실제 측정된 체압 분포 이미지의 라벨링 과정과 사용된 정량적 평가방법에 대해서 기술한다. 최종적으로 계산된 수치들을 바탕으로 제시한 알고리즘의 성능을 평가한 결과를 고찰한다.

II 본문

본 연구에서 제안하는 환자의 자세 추정을 위한 알고리즘은 두 가지의 인공신경망 알고리즘을 각 단계에 활용하

여 구성되었으며, 저해상도 체압 이미지의 고해상도 보정과 보정된 이미지를 통한 자세 검출의 과정을 각각 수행한다. 첫 단계에서는 고해상도 보정을 위한 SR기법인 super-resolution convolutional neural network (SRCNN) 와 SRCNN에서 고주파세부사항(high frequency detail)과 지각적인 부분이 보완된 SRGAN 기술을 이용하여 저해상도 전신 체압 분포 이미지를 고해상도 체압 분포 이미지로 보정하였다. 다음 단계에서는 보정된 이미지를 기반으로 one-hot encoding 기법을 이용한 자세 라벨링을 진행하여 CNN 기술을 이용한 자세 검출 네트워크를 학습하였다.

1. 저해상도 이미지의 해상도 향상 알고리즘

자세 추정을 위한 최적 결과를 얻기 위해서, 앞서 기술한 저해상도 이미지의 고해상도 향상 알고리즘인 SRCNN과 SRGAN의 두 가지 방식을 활용하여 학습을 진행하였다. SRCNN은 단일 이미지 초해상도(single image SR)에 최초로 딥러닝을 적용한 기술로써, 간단한 구조로 기존의 SR방법보다 좋은 성능을 보여 많은 연구자들이 SR 문제에 딥러닝을 적용하는 계기를 제공하였다. 그림 1과 같이 SRCNN은 저해상도 이미지를 입력 받아, patch extraction / representation, non-linear mapping, reconstruction의 과정을 거쳐 고해상도 이미지를 출력한다[5].

SRCNN은 학습 과정 중 손실함수, $L(\theta)$ 로 mean square error (MSE)를 사용한다.

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n \|F(Y_i; \theta) - X_i\|^2 \quad (1)$$

θ 는 CNN의 레이어들의 feature map의 크기와 패치의 차원을 나타내며 F 는 각 레이어들의 매핑 함수이며, Y_i 는 저해상도 이미지 데이터, X_i 는 고해상도의 이미지 데이터이다. MSE는 전체적인 학습에는 좋은 결과를 보이지만 고주파 영역의 특징을 나타내는 지표로는 좋은 성능을 보이지 못하여 이를 보완하기 위한 다양한 SR 딥러닝 모델들이 제안되고 있다.

SRGAN은 SRCNN에서의 MSE의 차이를 최소화함으로써 peak signal-to-noise (PSNR)을 높게 만들어 해상도를 향상시키는 방법으로, 이전 기술들의 고주파세부사항의 한계를 개선하기 위하여 개발된 네트워크이다. 그림 2와 같이 생성




그림 1. Super-resolution convolutional neural network (SRCNN) 을 이용한 해상도 향상 모델.

Fig. 1. Resolution enhancement model using SRCNN.




그림 2. Super-resolution generative advisory networks (SRGAN) 모델의 구성 예시.

Fig. 2. An example of SRGAN model architecture.

(generative) 네트워크와 판별(discriminative) 네트워크의 2개 네트워크로 구성된다. 판별 네트워크는 각각의 데이터 인스턴스가 실제 트레이닝 데이터 세트인지 아닌지를 구별하는 역할을 하고, 생성 네트워크는 주어진 저해상도 이미지를 그에 상응하는 고해상도 이미지 짝을 생성하는 생성 함수를 훈련한다. 생성네트워크가 생성한 ‘가짜’ 고해상도 이미지를 넣고 판별네트워크의 판정을 계속 받는 과정에서 점차 고해상도 이미지가 ‘진짜’ 이미지에 가까워지도록 소위 적대적 학습을 통해 결과를 도출하는 것이 핵심이다. 이러한 학습 과정을 통해서 최종적으로 생성네트워크는 판별네트워크를 속이기 위해 원본과 유사한 고해상도 이미지를 만들어 내는 결과를 보여준다.

SRCNN의 MSE 기반 loss function의 한계를 보완하고자 SRGAN에서는 픽셀공간에서의 유사성이 아닌 지각적 유사도(perceptual similarity)에 기반하여 콘텐츠 손실(content loss)와 적대적 손실(adversarial loss)로 구성된 지각적 손실함수(perceptual loss function)를 이용하여 이미지를 보정한다[6].

1.1. 콘텐츠 손실

일반적으로 MSE를 기반으로 할 때 pixel-wise MSE loss를 사용하지만 이러한 방식은 텍스처를 부드럽게 하는 효과로 고주파세부사항을 흐리게 보이게 한다. SRGAN에서는 이 문제를 해결하기 위하여 pre-trained model VGG19[7]의 activation function ReLU를 기반으로 콘텐츠 손실을 아래 수식 (2)와 같이 구성하였다.

$$l_{VGG}^{SR} = \frac{1}{W_{i,j} H_{i,j}} \sum_{x=1}^{W_{i,j}} \sum_{y=1}^{H_{i,j}} \left(\phi_{i,j}(I^{HR})_{x,y} - \phi_{i,j}(G_{\theta_G}(I^{LR}))_{x,y} \right)^2 \quad (2)$$

I^{LR} 은 low-resolution image, I^{HR} 은 high-resolution image이며, W_{ij} 와 H_{ij} 은 VGG19 네트워크 내의 각 feature map의 차원, ϕ_{ij} 은 VGG19 네트워크 내에서 i 번째 매핑 계층과 j 번째 컨볼루션에 의해 얻는 특성을 나타내며 $G_{\theta_G}(I^{LR})$ 은 저해상도 이미지가 고해상도로 재구성된 이미지이다.

1.2. 적대적 손실

이 부분은 이미지 손실을 최소화하기 위해 GAN에서 특이적으로 사용하는 방식으로, (1-x)는 훈련 초기 gradient가 flat한 경향이 있어 이것을 역으로 바꾼 -(x)방식을 사용한다. 아래 수식 (3)과 같이 변경된 방식은 gradient초기값은 매우 크게 나타나지만 generator가 고해상도인 상태로 훈련되기 위한 학습으로 좋은 효과를 보여준다[6].

$$l_{Gen}^{SR} = \sum_{n=1}^N -\log D_{\theta_D}(G_{\theta_G}(I^{LR})) \quad (3)$$

D_{θ_D} 은 재구성된 이미지 $G_{\theta_G}(I^{LR})$ 가 원본 고해상도 이미지일 확률이다.

위에 설명한 2가지의 손실 함수를 더하여 최종적으로 아래 수식 (4)와 같은 지각적 손실 함수가 완성된다[8].

$$l^{SR} = l_{VGG/i,j}^{SR} + 10^{-3} l_{Gen}^{SR} \quad (4)$$

본 연구에서는 그림 3과 같이 네트워크를 구성하였다. 기존의 판별 네트워크에서 체압 분포 이미지의 크기에 적합한 학습을 진행하기 위하여 판별네트워크 레이어의 kernel Size를 3×3으로 수정하였고 moment는 0.9, Leaky ReLU는 0.2, dropout은 0.2와 같이 기존의 유사한 SRGAN 구성 사례[9]에서 사용된 매개변수 값을 활용하여 구성하였다.

2. 체압분포이미지 자세 검출 알고리즘

자세 검출을 위해서는 그림 4와 같이 CNN 기반의 분류 알고리즘으로 구현하였으며, 손실 함수를 이용하여 실제 값과 추정 값의 차이를 최소화하는 파라미터들을 찾아가는 딥 러닝 형태로 구성하였다. 손실 함수는 MSE, binary cross-entropy, categorical crossentropy, sparse categorical crossentropy 등이 사용되는데, 본 연구에서는 3개의 환자 자세를 분류하는 목적을 고려하여, categorical crossentropy 기법을 이용하여 다중 클래스 분류 학습을 진행하였다.

3. 체압분포이미지의 획득 및 라벨링

총 3가지의 자세(supine, right log, left log)에 대한 압력 데이터셋은 각기 다른 2가지의 전신체압측정기를 이용하여 획득하였다. 데이터의 획득에는 계명대학교 사용성 평가 센




그림 3. 체압 분포 데이터에 맞추어 구성된 SRGAN 모델.

Fig. 3. Custom-tuned SRGAN model architecture for the body pressure data.




그림 4. 환자 자세 검출 알고리즘 모델.

Fig. 4. Patient posture detection model.

터의 전신체압측정기(Pliance, Novel Inc, U.S.A.)와 서




그림 5. 전신압력측정기 이용한 압력 측정 결과 예시.

Fig. 5. Examples of body pressure measurement using the pressure mat.

울아산병원에서 보유중인 전신체압측정기(BPMS, 테크스툼, 대한민국)을 활용하여 진행되었으며, 64×32 해상도의 이미

지 1800장과 48×16 해상도의 이미지 1200장을 획득하였다. 추가적으로, Vista Medical FSA SoftFlex로 측정된 open dataset[10]의 3가지 자세에 대해 64×32 해상도를 가진 이미지 3000장(각 1000장)을 네트워크 학습에 활용하였다.

위 3가지 자세 분류에 속하지 않는 기타 자세는 실측 데이터를 따로 만들지 않고, 위에 설명한 측정 데이터에 임의적인 변형을 가하여 - 각도 변환(-15°, -10°, -5°, 0°, 5°, 10°, 15°) - “others”의 네 번째 분류 데이터셋을 만들고, 총 4가지의 자세 형태(supine, right log, left log, others)로 데이터셋을 one-hot encoding을 기법으로 분류 학습을 진행하였다.

자세 분류를 위해 사용된 CNN에서 학습 데이터는 다음과 같이 세부 구성을 나누어 진행하였다. 학습 데이터는 대개 훈련용 데이터 집합(train set)과 학습이 이루어진 인공지능 엔진의 성능을 시험하는 시험용 데이터 집합(test set)으로 나누어 사용되는데, overfitting의 문제를 피하기 위해 훈련용 데이터도 다시 두 가지로 나누어, 처음 훈련용 데이터 집합과 검증용 데이터 집합(validation set)을 나누어, 초기

훈련 데이터로 어느 정도 정확도가 높아지고(손실 함수의 값이 낮아지고) 수렴되는 경향을 보일 때까지 학습을 한 후에 검증용 데이터를 통해 다시 학습을 시키면서 정확도의 변화 양상을 보아 일정한 수준에서 학습을 종료시키는 과정으로 진행된다[11]. 본 연구에서는 위에 설명된 데이터들을 6:3:1의 분량으로 각각 훈련, 검증, 시험 데이터로 사용하였다.

연구 과정의 제한적 상황으로 저해상도 데이터, 즉, 센서 숫자가 적은 실제 측정용 압력 센서 시스템의 개발이 완료되지 않아, 위에 설명된 고밀도 센서로 얻은 데이터, 고해상도 데이터를 1/4 downsampling 한 후에 이를 다시 bicubic interpolation 방식으로 scaling 하여 일부러 해상도를 낮춘 입력용 데이터를 생성하여 사용하였다.

4. 정확도 평가방법

정확도 평가에는 image quality assessment (IQA)을 활용하였다[12]. 영상 정보의 화질을 평가할 때 사용하는 지표인 PSNR은 아래 식 (5)와 같다. 품질이 좋은 이미지는 큰 PSNR값을 가지며, 품질이 좋지 않은 이미지는 작은 PSNR값을 가지게 된다.

$$PSNR = 20 \cdot \log_{10}(MAX_I) - 10 \cdot \log_{10}(MSE) \quad (5)$$

Structural similarity (SSIM)는 PSNR의 한계를 극복하기 위해 제안된 지표로서 정의는 아래와 같다. 사람의 지각 능력과 일치시키는 목적으로 개발되었다. 사람은 영상에서 구조 정보를 반영하여 영상을 바라보게 되는데, 영상이 얼마나 구조 정보를 변화시키는가를 측정하는 기술이다.

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (6)$$

$\mu_x, \mu_y, \sigma_x, \sigma_y, \sigma_{xy}$ 는 이미지 x, y의 국소 평균, 표준 편차, 교차 공분산이다.

고해상도 향상 이미지 결과물의 정확도는, 상기 두 가지의 이미지 평가 기술을 사용하여 평가되었으며, 자세 검출에 대한 CNN 알고리즘은 아래의 다중 분류 손실 함수를 이용하여 실측 값과 추정 값의 차이를 수식(7)과 같이 이용하여 정확도를 평가하였다.

$$CE = - \sum_i^C t_i \log \left(\frac{e^{s_i}}{\sum_j^C e^{s_j}} \right) \quad (7)$$

t_i 는 ground truth, s_i 는 각 클래스 i 에 대한 CNN의 마지막 층의 출력인 score 벡터의 i 번째 요소이다. C 는 분류할 카테고리의 수를 나타낸다.

III. 결과

그림 6~8은 체압 분포 데이터의 고해상도 복원 인공지능 알고리즘의 실제 출력 결과의 예시들이다. 입력으로 사용된 저해상도 이미지, SRCNN의 출력 결과, SRGAN의 출력 결과, 고해상도 이미지를 supine, right log, left log 각각 자세에 대해 예시를 보였다.

표 1은 고해상도 이미지와 SRCNN, SRGAN 출력 이미지

의 유사도 계산 결과를 나타낸다. SRGAN을 이용한 고해상도 복원 결과는 supine자세에서는 PSNR 37.17dB, SSIM 0.9622, right log 자세에서는 27.02dB, SSIM 0.9224, left log자세에서는 31.44dB, SSIM 0.9470으로 SRCNN 대비 높은 결과를




그림 6. Supine 자세의 이미지 비교 예시. (좌로부터) 입력 저해상도 이미지, SRCNN, SRGAN 이용 처리 결과, 원본 고해상도 이미지.

Fig. 6. Image comparison example of the supine posture. (From the left) low resolution image, SRCNN output, SRGAN output, and high-resolution image.




그림 7. Left log 자세의 이미지 비교 예시. (좌로부터) 입력 저해상도 이미지, SRCNN, SRGAN 이용 처리 결과, 원본 고해상도 이미지.

Fig. 7. Image comparison example of the left log posture. (From the left) low resolution image, SRCNN output, SRGAN output, and high-resolution image.




그림 8. Right log 자세의 이미지 비교 예시. (좌로부터) 입력 저해상도 이미지, SRCNN, SRGAN 이용 처리 결과, 원본 고해상도 이미지.

Fig. 8. Image comparison example of the right log posture. (From the left) low resolution image, SRCNN output, SRGAN output, and high-resolution image.

표 1. 압력 이미지 데이터 간 유사도.

Table 1. The similarity parameters between estimated images.

	SRCNN			SRGAN		
	Supine	Right Log	Left Log	Supine	Right Log	Left Log
PSNR (dB)	24.29	24.25	27.90	37.17	27.02	31.44
SSIM	0.8049	0.7389	0.7573	0.9622	0.9224	0.9470




그림 9. 자세 분류 알고리즘의 학습 과정 중 훈련 데이터와 검증 데이터 단계 정확도 변화 (시험 데이터에 대한 정확도 평가 결과 98.37%)

Fig. 9. Accuracy change during the training and validation processes of the body pressure estimation using image enhancement (test accuracy 98.37%)

보여주었다. 이미지를 육안 관찰로 정성적 비교해 보아도 SRGAN 결과가 상대적으로 보다 많은 고해상도세부사항을 보여주는 것으로 판단된다.

자세 검출 알고리즘은 그림 9와 같이 반복학습을 통하여 일정한 정확도에서 수렴함을 확인하였다. 시험 데이터 통한 정확도 평가 결과(test accuracy)는 98.37%이었다.

IV. 결론

임상 현장에서는 신체 특정 부위 중 눌러 있기 쉬운 부위들이 일정 시간 이상 지속적으로 압력이 가해진 상태가 되면 결과적으로 피부 조직의 변성이 일어나게 되는 욕창의 진행 과정과 발생 예측 위험에 대한 다수의 선행 연구의 결과를 따라 환자의 자세를 파악하고 이를 주기적으로

변화시켜 주는 것으로 기본적인 욕창 예방 효과를 얻고 있다. 본 연구에서는 인공지능 기반 초고해상도 복원 기법을 활용하여 저해상도 체압 데이터로부터 고해상도 체압 데이터를 추정하는 기술과 학습 기반으로 자세를 분류하는 기술을 구현하여 실용적인 저해상도의 체압 센서 기반의 환자 욕창 예방 기술을 제안하였다. 개발된 알고리즘을 이용하여 보정된 체압분포이미지는 원본 이미지와 높은 유사도를 나타내었고 환자 자세 분류 기술 역시 높은 정확도로 실용성을 입증하였다.

체압 분포 정보를 보다 정확히 알 수 있으면, 욕창 발생 예측의 정확도를 보다 높게 이루어낼 수 있으나, 이에 앞서 기본적인 단계로는 환자의 자세의 추정과 상대적으로 주변 보다 높은 압력 분포 지점의 확인 정도로도 일정 정도 임상적으로 유효한 효과를 얻을 수 있어, 본 연구에서는 체압 분포 추정의 정확도를 보다 높이는 것은 추후 과제로 두고, 자세 추정의 단계를 실용적으로 구현 가능한지 탐색해 보았다.

실제 임상 적용될 센서 시스템과 보다 고도화된 인공지능 네트워크를 통하여 자동적으로 욕창을 예측 및 예방하는 기술[4,13]로 최종 구현하는 임상 연구진과의 공동 연구를 다음 단계로 예정하고 있다.

REFERENCES

- [1] European Pressure Ulcer Advisory Panel (EPUAP), "Guidelines on treatment of pressure ulcers," EPUAP Rev. 1, pp. 31-33, 1999.
- [2] S. Tsuji, S. Ichioka, N. Sekiya, and T. Nakatsuka, "Analysis of ischemia-reperfusion injury in a microcirculatory model of pressure ulcers," *Wound Repair Regeneration*, vol. 13, no. 2, pp. 209-215, 2005.
- [3] D. Gawlitta, W. Li, C.W.J. Oomens, F.P.T. Baaijens, D.L. Bader, and C.V.C. Bouten, "The relative contributions of compression and hypoxia to development of muscle tissue damage: an in vitro study," *Annals of Biomedical Engineering*, vol. 35, no. 2, pp. 273-284, 2007.
- [4] M. B. Pouyan, J. Birjandtalab, M. Nourani, and M. D. M. Pompeo, "Automatic limb identification and sleeping parameters assessment for pressure ulcer prevention," *Computers in Biology and Medicine*, vol. 75, pp. 98-108, 2016.
- [5] C. Dong, C. C. Loy, K. He, and X. Tang, "Image super-resolution using deep convolutional networks," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, no. 2, pp. 295-307, 1 Feb. 2016. doi: 10.1109/TPAMI.2015.2439281.
- [6] C. Ledig, L. Theis, F. Huszár, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang, W. S. Titter, "Photo-realistic single image super-resolution using a generative adversarial network," *Proc. of the 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 105-114, 2017. doi: 10.1109/CVPR.2017.19.

- [7] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *the 3rd International Conference on Learning Representations (ICLR)*, pp. 1-14, 2015. arXiv:1409.1556v6 [cs.CV].
- [8] D. P. Kingma and J. L. Ba, "Adam: A method for stochastic optimization," *the 3rd International Conference on Learning Representations (ICLR)*, pp. 1-15, 2015. arXiv:1412.6980v9 [cs.LG].
- [9] J. Yoo, "Semi-supervised Generative Adversarial Network for Wi-Fi Fingerprint Based Indoor Location Awareness," *Journal of Institute of Control, Robotics and Systems (in Korean)*, vol. 26, no. 12, pp. 1116-1121, Dec. 2020.
- [10] H. Ahn, L. Cowan, C. Garvan, D. Lyon, and J. Stechmiller, "Risk factors for pressure ulcers including suspected deep tissue injury in nursing home facility residents: Analysis of national minimum data set 3.0," *Advances in Skin and Wound Care*, vol. 29, no. 4, pp. 178-190, 2016.
- [11] J.-E. Ha, "Detection of Korea License Plate by Mask R-CNN using Composite Image," *Journal of Institute of Control, Robotics and Systems (in Korean)*, vol. 26, no. 9, pp. 778-783, Sep. 2020.
- [12] C.-Y. Yang, C. Ma, and M.-H. Yang, "Single-image super-resolution: A benchmark," *Proc. of the 13th European Conference on Computer Vision (ECCV)*, pp. 372-386, 2014.
- [13] J. Seon, S. Jin, and J. Hyun, "Factors predicting the interface pressure related to pressure injury in intensive care unit patients," *Journal of Korean Academy of Nursing*, vol. 47, no. 6, pp. 794-805, 2017.



김진규

2020년 울산대학교 공과대학 의공학전공 학사. 2021년~현재 울산대학교 대학원 의과학과 의공학전공 석사과정 재학 중. 관심분야는 인공지능을 이용한 영상 처리.



심명훈

2009년 연세대학교 공과대학 기계공학과 학사. 2020년 동대학 박사. 2020년~현재 서울아산병원 의공학연구소 박사후 연구원. 관심분야는 착용형 외골격 로봇 시스템 개발, 다양한 기구 메커니즘 설계, 동역학 분석 및 제어 알고리즘 개발.




배은경

2010년 연세대학교 의용전자공학과(공학사). 2013년 연세대학교 의공학과(공학석사). 2019년~현재 주식회사 리모 대표이사. 관심분야는 영상인공지능, 2D/3D 모션분석, 행동분석, 생체역학



문영진

1996년 부산대학교 제어기계공학과 졸업. 1998년 동 대학원 정밀기계공학과 석사. 2011년 University of Florida Mechanical Engineering 박사. 2015년~현재 울산대학교 의과대학 및 서울아산병원 연구부교수. 관심분야는 로봇 기구학, 수술로봇 및 재활로봇, 지능형 제어 알고리즘 응용.



최재순

1995년 서울대학교 제어계측공학과 졸업. 2003년 동 대학원 의용생체공학 협동과정 박사. 1999년~2000년 Cleveland Clinic, OH, 연수연구원. 2004년~2007년 국립암센터 주임연구원. 2007년~2012년 고려대학교 의과대학 연구교수. 2012년~2016년 울산대학교 의과대학 및 서울아산병원 연구부교수. 2016년~현재 울산대학교 의과대학 의공학교실 및 서울아산병원 부교수. 관심분야는 수술 및 중재시술 로봇, 재활로봇, 가상현실 의료 응용, 의료 시뮬레이션 등.